Proposal: Probing Image and Video Foundation Representations via Shared Complete-3D Decoding

用共享的 complete-3D decoding probe 分析图像与视频 foundation representations

董嘉铖

2026 年 4 月 8 日

摘要

近年来，3D foundation models 与 video foundation models 在多视图几何理解、时空一致性建模、深度预测与 pointmap 回归等方向上取得了快速进展。然而，现有 3R/NVS 范式主要评估模型**各自输出头的最终结果**，却难以直接回答一个更基础的问题：**这些模型内部学到的 representation，究竟在多大程度上已经具备场景级 3D 结构，并能被稳定地解码为完整 3D 场景？**

本文提出一个以 **Shared Complete-3D Decoding Probe** 为核心的 probing framework。我们复用一个共享的 latent-to-point decoder 作为 probing interface，并用小型 **scene-token adapter** 将不同 frozen image/video representations 对齐到统一 latent space；与之对应，本文再引入一个极简的 **direct 3D readout baseline**，用来测量表征中可被直接读出的局部几何信息。

该对照使我们区分两类能力：一类是可被浅层 readout 直接恢复的局部 3D 信息，另一类是必须经共享 decoder 才能展开的 scene-level complete-3D structure。本文重点比较不同 representation family 在 low-view、unseen-region 与 layer / timestep 条件下的 decodability pattern，而不把贡献放在新的 decoder 设计上。

1 Introduction and Motivation

图像 foundation models 与 video foundation models 已经能够从单目、双目、多目图像或视频片段中提取深度、相机位姿、pointmap、时空特征以及更高层次的几何线索。这类模型在几何理解、视图一致性建模与场景表征学习上展现出很强的泛化能力，但现有分析仍主要停留在“最终输出是否准确”这一层面。换言之，我们知道某些模型的深度更准、pose 更稳、pointmap 更好，或具有更强的视频生成一致性，却并不真正清楚：**这些模型内部的 representation 是否已经足够结构化，以至于可以被统一的 probe 稳定读出，尤其是被解码为完整、连贯、可补全的 3D 场景。**

本文关注的问题是：**能否设计一个比现有 3R/NVS 输出指标更直接的 representation probe，用来揭示 3D 表征的场景级结构性？**与传统 3D benchmark 不同，本文不再主要比较端到端系统输出，而是比较**冻结表征本身的结构质量、可恢复性与可解码性**：若将不同模型的内部特征接入同一套 probe family，在极小适配代价下，谁更容易被直接读出稳定的 3D 属性，谁又更容易被还原为完整、可补全的场景结构？

这一切入点主要受三类工作启发。NOVA3R [1] 说明，紧凑的 scene-level latent 可以承载足以解码完整场景的全局信息；GLD [2] 说明，不同 foundation features 作为 decoding 中间空间时并不等价，而且中间层往往比最终层更适合作为几何解码接口；How Much 3D Do Video Foundation Models Encode? [3] 则说明，即便模型没有显式 3D 输出头，只要冻结特征中编码了 3D 结构，这些信息就可以通过受限 probe 被直接读出。三者共同表明：**“表征是否适合被 probe”本身就是一个值得单独研究的问题。**

基于这一动机，本文提出一个 **Shared Complete-3D Decoding Probe**。本文有两条核心主线：第一，在共享 latent-to-point decoder 下，经小型 scene-token adapter 展开的 complete-3D 质量可以揭示 direct readout 难以覆盖的 scene-level structure；第二，图像、多视图几何与视频 representations 在该 probe 下会呈现不同的 decodability pattern，尤其是在 low-view 与 unseen-region 条件下。除此之外，**layer** 仍被保留为正文主问题；对于视频模型，本文还分析一个有限 early/mid window 内的 **timestep** 是否比后期 timestep 更适合作为 probe target。

本文的新意不在于提出新的 complete-3D decoder，而在于把共享 latent-to-point interface 重新组织为跨模型 representation probe，并通过 **direct readout vs. shared decoding** 的对照，将 3D evaluation 从 output space 推进到 latent / probe space。

2 Method

设输入观测为 X。对于图像类模型，

$$X = \{I_1, I_2, \ldots, I_K\},$$

而对于视频类模型，

$$X = (V, \{t_i\}_{i=1}^{K}),$$

其中 V 为输入视频片段，$\{t_i\}$ 为参与 probe 的采样帧索引。对应的完整 3D 场景目标记为

$$P^* \in \mathbb{R}^{N\times 3},$$

其中 P^* 表示 complete point cloud（也可以替换为其它完整 3D 表达）。

上述写法对应本文统一的 probe 输入接口。首版实验将同时覆盖图像 / multi-view geometry foundation representations 与视频 foundation representations；为避免异构输入接口带来的混淆，正文将分别报告 within-family 排序、cross-family 对比，以及视频模型内部的 layer / timestep 分析。

对每个待评估模型 M 及其第 ℓ 个候选层，我们提取冻结表征

$$r_M^\ell = R_M^\ell(X).$$

本文的核心评测对象是一个 shared decoding probe，同时配备一个 direct readout baseline 作为对照：

Direct 3D readout baseline. 给定冻结表征 r_M^ℓ，训练一个浅层读出模块

$$\hat{y}_{M,\ell}^{\mathrm{dir}} = P_{\mathrm{dir}}(r_M^\ell),$$

其中 $\hat{y}^{\mathrm{dir}}_{M,\ell}$ 可以包含 point map、depth map、camera pose 或其它直接 3D 属性。直观上，若一个 representation 内部已经编码了可恢复的 3D 结构，那么在固定 probe capacity 和训练集下，浅层 readout 应该能达到更低误差。

Shared complete-3D decoding probe. 我们首先训练一个 canonical complete-3D autoencoder：

$$z = E_{\mathrm{canon}}(P^*), \qquad \hat{P} = \mathcal{D}_{\mathrm{canon}}(z),$$

其中 E_{canon} 为 canonical latent encoder，$\mathcal{D}_{\mathrm{canon}}$ 表示共享的完整解码过程，$z \in \mathcal{Z}$ 为 canonical complete-3D latent。训练完成后冻结 $\mathcal{D}_{\mathrm{canon}}$，再训练一个小型 **scene-token adapter**：

$$\tilde{z}^{\ell}_{M} = A^{\ell}_{M}(r^{\ell}_{M}), \qquad \hat{P}^{\ell}_{M} = \mathcal{D}_{\mathrm{canon}}(\tilde{z}^{\ell}_{M}).$$

若某个 representation 更接近 canonical complete-3D latent 所要求的结构，那么在固定的小型 scene-token adapter 容量与共享 decoder 下，它应当更容易被展开为完整、稳定、可补全的 3D 结构。

这里的关键限制为：

1. R^{ℓ}_{M} 完全冻结；
2. P_{dir} 与 A^{ℓ}_{M} 容量受限；
3. $\mathcal{D}_{\mathrm{canon}}$ 在所有模型间共享并冻结；
4. 所有模型共享相同训练数据、训练预算与评测协议。

于是，本文对每个 (M, ℓ) 记录两类量：

$$S_{\mathrm{decode}}(M, \ell), \qquad S_{\mathrm{direct}}(M, \ell),$$

其中前者是本文的**主 probe signal**，用于度量某个 representation 的 **complete-3D decodability**；后者是一个**对照信号**，用于度量该 representation 中可以被浅层 readout 直接恢复出的局部 3D 信息。本文的重点不在于构造单一综合分数，而在于比较这两类信号在不同模型、不同层级以及不同 stress-test 条件下是否一致。

Overview. 整个 probing pipeline 分为三个阶段，如图 1 所示。第一阶段只用 complete 3D supervision 学习一个 canonical decoder；第二阶段冻结所有待测模型，统一抽取图像或视频表征，并训练一个 lightweight scene-token adapter；第三阶段以 shared decoding probe 为主、direct readout 为对照基线，对不同 representations 进行统一比较。

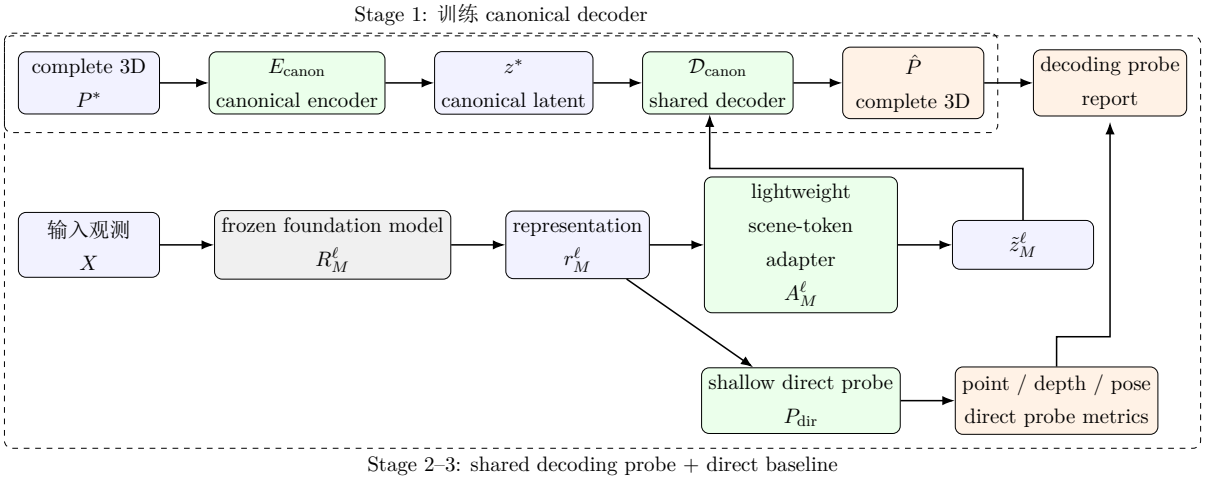

图 1: 统一 probing framework 流程图。Stage 1 先训练并冻结 canonical complete-3D decoder。随后，对每个待测模型抽取冻结表征，并通过一个小型 scene-token adapter 接入共享 decoder；该 adapter 使用固定数量的 learnable scene queries 从冻结表征中聚合出 scene tokens，再送入共享 decoder，测量其被解码为完整 3D 的难易程度。与此同时，在同一组 features 上训练一个受限的 direct readout baseline，用来估计可被浅层读出的 point/depth/pose 信息。本文以 shared decoding probe 为主，以 direct baseline 为对照。

2.1 Stage 1: Learning the Shared Latent-to-Point Interface

第一阶段，我们直接复用 NOVA3R [1] 的 **Stage-1 latent-to-point decoder family** 作为共享 canonical decoder 的来源，并在 complete point clouds 上训练一个 point-latent encoder-decoder：

$$P^* \xrightarrow{E_{\text{canon}}} z^* \xrightarrow{\mathcal{D}_{\text{canon}}} \hat{P}.$$

需要强调的是，NOVA3R 的原始目标是为其第二阶段图像模型提供一个冻结的 point decoder，而不是构造一个跨模型 probing benchmark。本文复用的是它的核心结构：先学习一个从 complete point cloud 到 latent scene tokens、再从 latent tokens 回到 complete point cloud 的 3D latent interface；随后再把这个 decoder family 重新组织为一个**跨模型共享的 probing interface**。

该阶段的目标是学习一个尽可能**通用、稳定、可共享**的 latent-to-point interface 及其对应 decoder。换言之，这一阶段并不是本文的最终 probe 本身，而是为后续 adapter-based probing 提供统一的 latent token 形状与共享 decoding procedure。本文第一版采用这种 point-latent 形式，是因为它最接近 NOVA3R 所展示的“scene-level latent → complete-3D output”路线，同时又能把论文重点保持在 representation probe 本身，而不是引入额外的 structured latent 设计变量。这里需要特别说明的是：本文严格复用的是 NOVA3R 的 conditional flow-matching point decoder family；而 canonical latent encoder E_{canon} 不必与 NOVA3R Stage 1 完全同构，在实现上允许采用更稳定的 slot-based point encoder 来生成固定长度的 canonical scene tokens，但这只是为了提高 probing stability，而不是本文的新方法主张。

具体地说，给定训练集中的 complete point cloud P^*，point-latent encoder 输出 latent code

$$z^* = E_{\text{canon}}(P^*), \qquad z^* \in \mathbb{R}^{N_s \times d},$$

其中 N_s 是固定的 scene-token 数，d 是 token dimension。完整解码过程 $\mathcal{D}_{\text{canon}}$ 接收 z^* 并生成 complete point cloud

$$\hat{P} = \mathcal{D}_{\text{canon}}(z^*).$$

在实现上，Stage 1 的 supervision 也将尽量贴近 NOVA3R：若缺少显式 mesh supervision，则先将 dense views 回投并聚合为单个 complete point cloud，再通过 voxel filtering 与 farthest point sampling 获得更均匀的训练目标。训练目标写为：

$$\mathcal{L}_{\text{canon}} = \mathcal{L}_{\text{FM}},$$

其中 $\mathcal{L}_{\text{FM}}$ 是下文定义的 flow-matching 目标。与 NOVA3R 类似，本文第一版不强调 KL 或其它 latent regularization，而是直接通过 flow-matching loss 学习 point-latent interface。训练完成后，$\mathcal{D}_{\text{canon}}$ 将被完全冻结；后续所有模型都必须通过同一个 frozen decoding procedure 生成 complete 3D。因此，本文关于 decodability 的核心结论默认都是 **decoder-conditional**：我们比较的是不同 representations 在同一个 probing interface 下的表现，而不是对所有 decoder family 都成立的绝对排序。本文把这一步所学到的 latent token interface 视为一个 **canonical probing target**，但这一定义是本文为了 probing 而引入的重新组织方式，而不是 NOVA3R 原文对 Stage 1 的直接命名。

2.2 Canonical Decoder Architecture

为了避免将 $\mathcal{D}_{\text{canon}}$ 写成一个含糊的黑盒，本文第一版将其具体实现为一个 **conditional flow-matching point decoder**。更具体地说，我们用 $f_\theta(X_t, Z, t)$ 表示逐步预测 velocity 的网络，而用 $\mathcal{D}_{\text{canon}}(Z)$ 表示从噪声初始化出发、通过固定积分步骤得到完整点云的**完整解码过程**。结构参考 NOVA3R [1] 的 Stage-1 point decoder，但用途不同：NOVA3R 用它服务于自身的 image-to-scene-token 模型，而本文将其冻结后作为跨模型 representation probe。

Inputs and outputs. Decoder 的条件输入是 canonical latent tokens

$$Z = \{z_m\}_{m=1}^{N_s}, \qquad Z \in \mathbb{R}^{N_s \times d}.$$

在本文的 probing protocol 中，N_s 是所有模型共享的固定 scene-token 数，也是冻结 decoder 的固定输入长度；它与输入视角数/帧数 K 无关。这样 Stage 2 的任务就不是保留原始 token 数，而是把任意长度的冻结表征聚合为同样长度的 scene tokens，再送入共享 decoder。输出不是 occupancy grid 或 SDF，而是一组 non-pixel-aligned complete 3D points：

$$\hat{P} = \{\hat{x}_i\}_{i=1}^{N_q}, \qquad \hat{P} \in \mathbb{R}^{N_q \times 3}.$$

其中 N_q 是 decoder query budget。第一版将固定 N_q（例如与训练点数一致），并在 evaluation 中通过改变 N_q 画 quality–budget 曲线；也就是说，本文暂时不让 decoder 自己决定点数，而是用固定 query budget 更干净地比较 representation 本身。

Flow-matching formulation. 训练时，从 ground-truth complete point cloud 中采样 N_q 个目标点，记为

$$X_0 = \{x_i^0\}_{i=1}^{N_q}.$$

采样噪声点

$$\epsilon = \{\epsilon_i\}_{i=1}^{N_q}, \qquad \epsilon_i \sim \mathcal{U}(-1,1)^3,$$

并采样时间 $t \sim \mathcal{U}(0,1)$。中间状态定义为

$$X_t = (1-t)X_0 + t\epsilon.$$

Velocity network 接收 noisy point queries X_t、条件 latent tokens Z 和时间 t，并预测 flow velocity：

$$V_\theta = f_\theta(X_t, Z, t), \qquad V_\theta \in \mathbb{R}^{N_q \times 3}.$$

对应的 flow-matching 监督为

$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}_{X_0,\epsilon,t}\left[\|f_\theta(X_t, Z, t) - (\epsilon - X_0)\|_2^2\right].$$

这里 velocity target 是从 data point X_0 指向 noise point ϵ 的方向；推理时从 noise 初始化，并沿反向时间积分恢复 clean point cloud。该设计的好处是：decoder 不需要对无序点云建立固定 point-to-point 对应，也不需要 scene-level occupancy/SDF supervision。

Tokenization and time conditioning. Decoder 内部维护两类 token：

$$Q_t = \psi_x(X_t) + \psi_t(t), \qquad Z = \{z_m\}_{m=1}^{N_s},$$

其中 $Q_t \in \mathbb{R}^{N_q \times d}$ 是 noisy point query tokens，ψ_x 是 3D 坐标投影 MLP，ψ_t 是 time embedding。所有 point queries 共享同一组 latent tokens Z 作为条件。最终输出 head 是一个 MLP：

$$H_{\mathrm{vel}} : \mathbb{R}^d \to \mathbb{R}^3,$$

将更新后的 point query token 映射为每个 query point 的 velocity。

Joint transformer block. 直接在 N_q 个 point query 上做全 self-attention 代价很高，因此本文采用 NOVA3R 中的 joint decoder block 思路。每个 decoder block 包含三步：

1. **Point-to-latent cross-attention:** 用 latent tokens Z 作为 query、point tokens Q_t 作为 key/value，将当前 noisy point set 的信息聚合到较短的 latent token set 中：

$$Z' = \mathrm{CrossAttn}(Q = Z,\ K = Q_t,\ V = Q_t).$$

2. **Latent self-attention:** 在 N_s 个 latent tokens 上做 self-attention，混合全局场景上下文：

$$Z'' = \mathrm{SelfAttn}(Z').$$

   由于 $N_s \ll N_q$，这一层比直接在所有 query points 上做 self-attention 更高效。

3. **Latent-to-point cross-attention:** 用 point tokens Q_t 作为 query、更新后的 latent tokens Z'' 作为 key/value，把全局上下文投回每个 noisy point query：

$$Q'_t = \mathrm{CrossAttn}(Q = Q_t,\ K = Z'',\ V = Z'').$$

多个 joint blocks 串联后得到最终 point query tokens $Q_t^{(B)}$，再经 velocity head 输出

$$V_\theta = H_{\mathrm{vel}}(Q_t^{(B)}).$$

第一版可采用较浅的 decoder，例如 $B = 3$ 个 joint transformer blocks，以便让 probe 的主要差异来自输入 representation，而不是过强的 decoder capacity。

Inference. 推理时，给定任意 adapted latent $\tilde{z}_M^\ell$，先采样初始 noisy queries：

$$X_1 \sim \mathcal{U}(-1,1)^{N_q \times 3}.$$

随后用 frozen velocity network 预测 velocity，并从 $t = 1$ 到 $t = 0$ 做固定步长的 ODE / Euler integration：

$$X_{t-\Delta t} = X_t - \Delta t\ f_\theta(X_t, \tilde{z}_M^\ell, t),$$

最终得到

$$\hat{P}_M^\ell = X_0.$$

因此，完整解码过程可记为 $\hat{P}_M^\ell = \mathcal{D}_{\mathrm{canon}}(\tilde{z}_M^\ell)$。所有被 probe 的 representation 使用**同一个** N_q、同一个采样 schedule、同一个 frozen velocity network 和同一个 inference step size。这样 probe score 的差异主要来自 representation 与 canonical latent space 的适配程度。

2.3 Stage 2: Lightweight Scene-Token Adapter

对于每个待评估模型 M 及其第 ℓ 个候选层，定义其 frozen representation 为：

$$r_M^\ell = R_M^\ell(X).$$

这里 R_M^ℓ 可以来自不同模型的不同层或不同 token interface，例如 VGGT 的中间层/最终层特征、DA3 的多层几何特征、DUSt3R / MASt3R 的 dense correspondence 特征、π^3 / Pi3 的 multi-view geometry features，以及视频 foundation models 的时空特征。对于视频模型，具体的帧采样、layer / timestep 选择与特征抽取协议统一放在 Experimental Protocol 中说明，而不作为 Stage 2 主方法的一部分。

受 GLD [2] 的 layer-selection 分析启发，本文不会默认最终层一定最适合 complete-3D decoding，而是将 layer index ℓ 本身纳入 probe。与此同时，本文不再坚持 token-preserving 的接口假设。原因在于，冻结表征要接入共享 decoder 时，真正需要解决的是两个问题：其一是**场景级信息聚合**，其二是 **decoder-space latent 对齐**。单纯保持 token 数不变，并不能保证这两点。

因此，Stage 2 的核心模块是一个 **lightweight scene-token adapter**。它保留 NOVA3R Stage 2 中“learnable scene tokens 聚合任意数量视角信息”的核心思想，但把原始的大型 visual transformer 替换为针对 frozen features 的轻量 adapter。正文主方法只保留最小核心接口：

feature normalization、learnable scene queries、单层 cross-attention 聚合与 token projection。其整体链条写为：

$$r_M^\ell = R_M^\ell(X), \qquad T_M^\ell = \phi_{\text{norm}}(r_M^\ell) \in \mathbb{R}^{L\times d},$$
$$S_0 \in \mathbb{R}^{N_s\times d}, \qquad S_1 = \text{CrossAttn}(Q = S_0,\ K = T_M^\ell,\ V = T_M^\ell),$$
$$\tilde{z}_M^\ell = A_{\text{proj}}(S_1) \in \mathbb{R}^{N_s\times d}, \qquad \hat{P}_M^\ell = \mathcal{D}_{\text{canon}}(\tilde{z}_M^\ell).$$

Feature normalization. 这里 ϕ_{norm} 只负责最小统一化，而不承担 scene aggregation。更具体地说，ϕ_{norm} 只包含通道投影到统一维度 d、必要的 spatial resize / flatten、frame / view positional encoding 与 layer norm。经过这一步后，不同 backbone 的输出都被整理为一个 source token set

$$T_M^\ell \in \mathbb{R}^{L\times d},$$

其中 L 是 source token length，它随输入视角/帧数 K、特征分辨率以及 backbone interface 而变化；这一步不做 pooling，不做 scene-level fusion，也不把 L 绑定到 decoder 的输入长度。若 batch 内存在不同长度的 source tokens，则使用 padding 与 attention mask 统一计算，但这不改变方法定义本身。

Learnable scene queries. 为了把任意长度的 source token set 聚合成 decoder 可接受的固定长度 scene latent，本文引入一组固定数量的 learnable scene queries：

$$S_0 \in \mathbb{R}^{N_s\times d}.$$

其中 N_s 是所有模型共享的固定 scene-token 数，与输入视角数 K 无关。它同时决定了 adapter 输出的 latent 长度和冻结 decoder 的条件输入长度。

Cross-attention aggregation. 给定 T_M^ℓ 与初始 scene queries S_0，adapter 首先用一层 cross-attention 聚合冻结表征中的场景信息：

$$S_1 = \text{CrossAttn}(Q = S_0,\ K = T_M^\ell,\ V = T_M^\ell).$$

这一步对应的正是 NOVA3R Stage 2 的核心逻辑：不是让 image / video tokens 直接充当 decoder latent，而是先让少量 scene tokens 从任意数量的 source tokens 中汇聚出场景级几何上下文。与 NOVA3R 不同的是，本文这里的聚合器是一个**受限的小型 probe adapter**，而不是完整的图像 transformer 主干。

Projection and optional stabilization. 在默认设置下，A_{proj} 直接把 S_1 映射为最终 latent scene tokens；它可以是逐 token 的线性层或两层 MLP。这里的关键点是：adapter 的核心职责是 **scene-level aggregation + decoder-space alignment**，而不是简单维度投影。

若个别 backbone、视频 timestep 或低资源设置下训练不稳定，可以在 S_1 与 A_{proj} 之间插入一个可选的极小 refinement 模块；该模块最多包含 1 个 self-attention + FFN block，只作为稳定化实现细节，而不构成本文主方法的核心接口。相应地，首版协议中 adapter 的容量被显式限制为：cross-attention 层数固定为 1，optional refinement 最多为 1 个 block，不使用多层 alternating global attention，也不引入额外的 decoder-side latent queries。本文主结论建立在 **small-adapter regime** 下；更强 adapter 仅作为稳健性检查，不参与核心结论定义。

Training objective. Stage 2 的默认监督来自冻结 decoder 上的 flow-matching 目标。给定 Stage 1 中同样的 noisy point queries X_t，定义

$$\tilde{v} = f_\theta(X_t, \tilde{z}_M^\ell, t),$$

并最小化

$$\mathcal{L}_{\mathrm{FM}} = \mathbb{E}_{X_0,\epsilon,t}\left[\left\| f_\theta(X_t, \tilde{z}_M^\ell, t) - (\epsilon - X_0)\right\|_2^2\right].$$

这也是正文中定义 probe 的主训练目标。为了让 adapter 在少数难收敛的设置下更稳定地学会“什么样的 latent 对冻结 decoder 来说是可用的”，实现上还可以额外加入一个轻量的 decoder-behavior stabilization 项。对同一个训练样本，先通过 Stage 1 encoder 得到 canonical teacher latent

$$z^* = E_{\mathrm{canon}}(P^*),$$

再在相同的 noisy queries 上得到 teacher decoder behavior：

$$v^* = f_\theta(X_t, z^*, t), \qquad \tilde{v} = f_\theta(X_t, \tilde{z}_M^\ell, t).$$

定义稳定项

$$\mathcal{L}_{\mathrm{vel}} = \|\tilde{v} - \mathrm{sg}(v^*)\|_2^2.$$

若启用该稳定项，则 Stage 2 训练目标写为

$$\mathcal{L}_{\mathrm{probe}} = \mathcal{L}_{\mathrm{FM}} + \lambda_{\mathrm{vel}}\mathcal{L}_{\mathrm{vel}}.$$

其中 f_θ 与 $\mathcal{D}_{\mathrm{canon}}$ 都来自 Stage 1 并在此阶段完全冻结；优化的只有 ϕ_{norm}、scene queries、optional refinement 与 A_{proj}。$\mathcal{L}_{\mathrm{vel}}$ 的角色只是可选 regularizer，而不是新的主贡献；论文的核心比较对象仍然是不同 frozen representations 在同一 shared decoder 下的可解码差异。

Fairness. 为了保证 probe 结论反映 representation，而不是适配器工程细节，本文对不同模型统一以下设置：ϕ_{norm} 的最小接口、固定 scene-token 数 N_s、固定 scene-query 数量、统一 core adapter shape、统一 decoder、统一训练数据与训练预算。本文所有主结论优先在 **small-adapter regime** 下报告，以避免 adapter 本身学到完整 3D 重建能力而削弱 probe 的解释性；更强 adapter 只作为稳健性检查。对于视频模型，额外统一 frame-sampling、reference-frame protocol 与 layer / timestep 搜索空间；正文同时报告 within-family 与 cross-family 两类结论，避免把单一总榜解释得过强。

2.4 Stage 3: Shared Decoding Probe with a Direct Baseline

A. Direct 3D readout baseline. 在同一组 frozen features 上，本文以一个极轻量 direct baseline 作为 shared decoding probe 的主对照：

$$\hat{y}_{M,\ell}^{\text{dir-A}} = P_{\text{dir-A}}^\ell(T_M^\ell).$$

其中，A 档采用 linear / MLP readout，用来测量冻结 representation 中**可被直接读出的局部几何信息**。该 baseline 的输出可以包含三类直接 3D 属性：

- dense point map；
- dense depth map；
- relative camera pose。

该 baseline 的目标不是做到最强重建，而是在固定 probe capacity 下测试：给定 frozen representation，浅层 readout 到底能恢复出多少 globally consistent 3D structure。作为稳健性检查，本文还可以加入一个 tiny-transformer 版本的 direct baseline B，但正文主结果与核心 claims 不依赖该 stronger control。

B. Shared complete-3D decoding probe. 将 $\hat{z}_M^\ell$ 输入共享解码过程 $\mathcal{D}_{\text{canon}}$ 得到 $\hat{P}_M^\ell$，并与 ground-truth complete 3D 比较。由于 decoder 完全共享，而训练监督也与 Stage 1 / NOVA3R-Stage-2 保持同构，因此不同 representation 的差异主要反映在：它们能否在同一个 lightweight scene-token adapter family 的帮助下产出足够好的 scene tokens，从而条件化同一个 latent-to-point decoder。

因此，本文对每个 (M, ℓ) 同时记录主 probe 与对照基线两类信号：

$$S_{\text{decode}}(M, \ell) = F_{\text{decode}}(\mathcal{M}_{\text{recon}}, \mathcal{M}_{\text{unseen}}, \mathcal{M}_{\text{eff}}, \mathcal{M}_{\text{robust}}),$$

$$S_{\text{direct}}(M, \ell) = F_{\text{direct}}(\mathcal{M}_{\text{pmap}}, \mathcal{M}_{\text{depth}}, \mathcal{M}_{\text{pose}}),$$

其中 $F_{\text{decode}}(\cdot)$ 与 $F_{\text{direct}}(\cdot)$ 可以是标准化后的加权和，也可以保留为多维指标向量。本文的重点是以 S_{decode} 作为主 probe signal，系统比较它与 S_{direct} 在不同模型、不同层级以及不同 stress-test 条件下是否一致。

3 Experimental Protocol

3.1 Models, Data, and Fairness

首批待测对象将同时覆盖图像 / multi-view geometry foundation representations 与视频 foundation representations。图像侧优先纳入 VGGT [4]、DA3 [5]、DUSt3R [6]、MASt3R [7] 与 π^3 / Pi3 [8]，并系统分析 **single-layer vs multi-layer** 与 **middle-layer vs final-layer**；视频侧优先纳入 [3] 中覆盖的代表性模型，如 WAN2.1、Open-Sora2.0、CogVideoX 与 V-JEPA，并重点比较 **selected mid layer vs final layer**。对于 diffusion-based video models，正文不做全量 timestep sweep，而是依据 [3] 与 [2] 的观察，把 timestep 搜索限制在一个有限的 **early/mid window** 内。视频特征抽取统一遵循固定 protocol：frame sampling、reference-frame 设置以及受限的 layer / timestep 搜索空间。

数据侧采取两阶段策略。**Phase 1 / main results** 优先选择 complete 3D target 定义最清晰、最可靠、能够直接提供 complete geometry supervision 或稳定 complete point cloud 的数据，用于报告正文主结论；**Phase 2 / extension analysis** 再扩展到 complete point cloud 需要 operational approximation 的场景数据，用于检验结论的外推稳定性。两阶段数据都需要满足三点：能够定义相对稳定的 complete 3D 目标，能够区分 observed / unobserved regions，并且能够以统一协议输入到多个 representation models 中。本文将采用一个统一的可见性定义：

对每个输入视角，把 complete point cloud P^* 投影到该视角，并通过 z-buffer 可见性与深度容差 δ 标记可见点；至少在一个输入视角中可见的点记为 P^*_{obs}，其余点记为 $P^*_{\text{unobs}} = P^* \setminus P^*_{\text{obs}}$。对视频模型，输入视角集合由采样帧协议决定。

为确保 probe 测量的是 representation，而不是适配器工程细节，全文将严格控制以下条件：冻结 encoder；共享 canonical decoder；统一 shallow direct probe family 与 lightweight scene-token adapter family；统一固定 scene-token 数 N_s、训练数据、优化器、训练步数与学习率计划。adapter 容量（small / medium / large）将作为单独变量报告，用于检查 probe 是否被过强的适配器掩盖；正文主结论优先报告 small-adapter regime 下的结果。

3.2 Metrics

本文将评测指标拆成 **主结果**与 **分析结果**两层。主结果用于支撑正文核心结论，分析结果用于补充解释 representation family、feature layer 与 video timestep 的结构差异。

Main results.

- **Direct readout quality.** 正文主结果报告 direct baseline A（linear / MLP）上的 point map、depth map 与 relative pose 误差，用于衡量冻结 representation 在不经过 scene-level decoding 时，是否已经足以支持浅层 readout 恢复 globally consistent 3D attributes。direct baseline B（tiny transformer）只在稳健性分析中补充报告。

- **Decoding reconstruction quality.** 对 shared complete-3D decoding branch，记录 Chamfer Distance、Earth Mover's Distance（若可承受）、Completeness / Coverage 与 Normal Consistency，用于衡量统一 decoder 下的 complete-3D reconstruction 质量。

- **Unobserved-region completion.** 为避免 probe 只测可见区域拟合，本文在 P^*_{obs} 与 P^*_{unobs} 上分别报告 visible-region reconstruction 与 unseen-region completion。这一项用于判断 representation 是否包含 scene-level complete-3D prior。

Analysis results.

- **Budget efficiency.** 除了比较绝对误差，本文还比较 direct-probe quality vs probe capacity、decoding quality vs latent dimension、decoder query budget 与 adapter capacity。若某一 representation 在更小 probe 或更小 budget 下达到相同质量，则说明其内部结构更容易被统一 probe 利用。

- **Localization.** 在不同输入视角数或采样帧数 $K \in \{1, 2, 4, 8\}$ 下，比较低视角、稀疏采样、大遮挡、未观测区域增大时的退化曲线，并系统分析不同 feature layers 与受限 video timesteps 的表现差异。

4 Main Challenges and Risks

- **Canonical decoder 可能带来偏置。**若 canonical decoder 本身偏向某类 latent，probe 结论就会受到 decoder family 影响。本文将明确承认结论是 **decoder-conditional** 的：第一

版主实验不承诺同时比较多套 decoder family，而是用一个更弱或更简单的 latent interface 做 sanity check，检验核心排序是否稳定；多 decoder family 的一致性留作后续扩展。

- **Adapter 过强可能掩盖 representation 差异。**若 adapter 自己学会 complete 3D 任务，就会弱化 probe 的解释性。缓解方式是严格限制 adapter 参数量，并系统报告 performance vs adapter size，优先关注 small-adapter regime。
- **Ground-truth complete 3D 的定义并不总是稳定。**尤其在 unobserved region 上，complete geometry 往往存在 operational ambiguity。缓解方式是把正文主结论限制在 Phase 1 的 reliable targets 上，并把需要 operational approximation 的场景放入 Phase 2 extension analysis，单独报告 visible / unobserved 两类指标。
- **Cross-family comparison 仍可能不完美。**即使采用统一的训练与评测协议，图像 / geometry models 与视频 models 在输入接口、时空组织、特征分辨率和 token 组织方式上仍有差异。缓解方式是严格固定 feature normalization、frame-sampling 与 reference-frame protocol，并同时报告 within-family 排序与 cross-family 对比，避免过度解读单一总榜。

5 Expected Contributions

本文预期贡献如下：

1. 提出一个新的 3D representation probe：**Shared Complete-3D Decoding Probe**，用统一的 latent-to-point decoder interface 衡量不同图像与视频 foundation representations 的 scene-level 3D decodability；
2. 以一个极简的 **direct 3D readout control** 作为主对照，区分“可直接读出的局部几何信息”与“可经共享 decoder 展开的完整场景结构”；
3. 在统一 protocol 下系统研究 representation family、feature layer 与 video timestep 对 complete-3D decodability 的影响，并分析 image/video representations 在 low-view 与 unseen-region regimes 下的差异。

6 Possible Extensions

为避免首版 proposal 承担过多主线，以下想法暂不作为本文的核心贡献，而是作为后续可扩展方向保留：

- **多模态集成。**将 3D representation 作为额外结构 token 接入 vision-language 或 video-language models，通过 concat、cross-attention 或 memory fusion 的方式参与推理。
- **Downstream validation。**若后续实验条件允许，可以再考察 probe score 与若干几何或多模态任务之间的关系，但这将作为外部验证而非本文主线。
- **更广的 probe family。**当前 proposal 以 point-based canonical decoder 为主，未来可以扩展到 occupancy、Gaussian、surfel 或 mesh-aware 输出形式，以检验结论的稳定性。

参考文献

[1] NOVA3R. Non-pixel-aligned visual transformer for amodal 3D reconstruction.

[2] GLD. Repurposing geometric foundation models for multi-view diffusion.

[3] Huang et al. How much 3d do video foundation models encode?

[4] VGGT. Visual geometry grounded transformer.

[5] Depth Anything 3. Geometric foundation model for depth and multi-view geometry.

[6] DUSt3R. Geometric 3D vision made easy.

[7] MASt3R. Grounding image matching in 3D.

[8] π^3 / Pi3. Scalable permutation-equivariant visual geometry learning.